

Misogyny Index in Song Lyrics: a computational analysis of rhythms in the Metropolitan Region of Recife

Bianca Nathally Bezerra de Lima

bnbl@cin.ufpe.br

1 de junho de 2026

Este relatório descreve o pipeline técnico-metodológico desta pesquisa, fundamentado na baseline de Betti, Abrate e Kaltenbrunner (2023) e adaptado ao contexto dos ritmos populares da Região Metropolitana do Recife (RMR) e ao português do Brasil.

1 Visão geral do pipeline

O *pipeline* proposto compreende 14 etapas organizadas em cinco módulos funcionais: (i) coleta e curadoria do corpus; (ii) pré-processamento textual; (iii) detecção de misoginia por aprendizado de máquina; (iv) análise de viés de linguagem por *word embeddings*; e (v) cálculo e análise do Índice de Misoginia. A Tabela 1 consolida, para cada etapa, o módulo ao qual pertence, os *notebooks* correspondentes da *baseline* e o recurso computacional principal utilizado na adaptação proposta.

A *baseline* é implementada em dois conjuntos de *notebooks* denominados *notebooks_colab/* e *notebooks/*, referenciados ao longo deste capítulo pelos prefixos 1_*, 3_*, 4_* e 2_*, respectivamente. Os *notebooks* 1_* e 3_* cobrem o fluxo de construção do corpus, treinamento e aplicação do classificador; os *notebooks* 2_* implementam o sub-*pipeline* de análise de viés de linguagem; e os *notebooks* 4_* realizam as análises finais.

Tabela 1: Etapas do *pipeline*, módulos e *notebooks* da *baseline*.

#	Módulo	Etapas	Notebooks	Recurso / Adaptação
1	Coleta	Coleta de músicas e letras	1_0_0, 1_1_0	Spotify API + Letras.mus.br
2	Coleta	Filtragem básica do corpus	1_2_0, 1_2_1	<i>langdetect</i> (PT-BR)
3	Coleta	Deteção e remoção de duplicatas	1_3_0 a 1_4_1	Jaccard em 3-gramas
4	Coleta	Enriquecimento de popularidade	1_5_0, 1_6_0	popularity/streams Spotify
5	Pré-proc.	Normalização, tokenização, lematização	— novo —	spaCy pt_core_news_sm
6	Class.	Anotação e dataset de treino	— novo —	AMI / OffComBR / codebook próprio
7	Class.	Fine-tuning do classificador	1_7_0, 1_7_1	BERTimbau (<i>bert-base-portuguese-cased</i>)
8	Class.	Aplicação ao corpus; score por música	3_0_0 a 3_0_2	Janela deslizante de 4 linhas
9	Viés	Extração de nomes próprios do corpus	2_0_1	API de nomes IBGE (em vez do SSA/EUA)
10	Viés	Construção e balanceamento dos word sets	2_0_2 a 2_0_4	WEAT1+2 traduzidos para PT-BR
11	Viés	Busca de hiperparâmetros Word2Vec	2_1_0, 2_1_1	Gensim + WS353-PT
12	Viés	Treinamento W2V (5 seeds) + WEAT	2_2_0 a 2_2_2	WEAT / SC-WEAT / SWEAT em PT-BR
13	Índice	Cálculo do Índice de Misoginia	— novo —	—
14	Resultados	Análise e visualização	4_0_1, 4_0_2	<i>matplotlib</i> + <i>seaborn</i>

2 Coleta de dados

2.1 Corpus de músicas via API do Spotify

A identificação das músicas de cada gênero é realizada por meio da API Web do Spotify, que disponibiliza dados sobre artistas, álbuns, faixas e *playlists*. São consultadas *playlists* oficiais e editorialmente curadas para cada gênero, além de *playlists* de usuários com elevado número de seguidores associadas aos gêneros em questão. Para cada faixa identificada, são coletados os seguintes metadados: identificador único da faixa (*track_id*), nome da faixa, identificador e nome do artista, gênero musical, índice de popularidade (campo *popularity*, escala inteira de 0 a 100) e ano de lançamento.

Diferentemente da *baseline*, que utiliza o banco de dados WASABI — uma coleção pré-existente de aproximadamente 2 milhões de músicas em inglês catalogadas com metadados (Meseguer-Brocal et al., 2017) —, o presente trabalho constrói o corpus do zero. Esta escolha é necessária dado que nenhuma base de dados pública disponibiliza de forma sistemática músicas dos gêneros trabalhados com metadados suficientes para a análise proposta. A *baseline* utiliza os dados do Billboard Hot 100 (1958–2010) como *proxy* de popularidade; neste trabalho, o índice de popularidade do Spotify desempenha papel análogo, com a vantagem de ser diretamente quantitativo, disponível para todas as músicas do corpus e semanticamente mais preciso para o mercado musical brasileiro.

2.2 Coleta de letras

As letras das músicas identificadas são coletadas por meio de fontes complementares: a API do Vagalume/Letras.mus.br/Genius, as maiores bases de letras de músicas em língua portuguesa disponíveis publicamente. O pareamento entre as músicas identificadas via Spotify e as letras coletadas é realizado por correspondência aproximada de *strings* (artista + título), utilizando o pacote *rapidfuzz* para o cálculo da distância de Levenshtein normalizada, em abordagem análoga à empregada por Betti et al. (2023) para o pareamento com os dados do Billboard. Músicas para as quais não é encontrada correspondência com confiança mínima nas fontes consultadas são descartadas do corpus.

2.3 Filtragem básica

Adotam-se critérios de filtragem análogos aos da *baseline* para garantir a qualidade mínima do corpus. A Tabela 2 apresenta os critérios adotados, seus valores e respectivas justificativas.

Tabela 2: Critérios de filtragem do corpus.

Critério	Valor / Condição	Justificativa
Extensão mínima	≥ 10 palavras	Eliminar faixas instrumentais ou com letras incompletas
Linhas mínimas	≥ 4 linhas	Garantir ao menos um lote para a janela deslizante do classificador
Ano de lançamento (se necessário)	Disponível	Necessário para análise temporal
Idioma	PT-BR (conf. $\geq 0,9$)	Excluir faixas em espanhol ou inglês (biblioteca <i>langdetect</i>)
Letra disponível	Sim	Fonte primária da análise; músicas sem letra são descartadas

2.4 Detecção e remoção de duplicatas

A detecção de duplicatas segue o método de Betti et al. (2023): cada letra é representada como um conjunto de 3-grams de palavras (*bag-of-words*), e dois itens são classificados como duplicatas quando o índice de Jaccard entre suas representações supera um limiar δ :

$$\text{Jaccard}(A, B) = \frac{|A \cap B|}{|A \cup B|} \geq \delta$$

A *baseline* adotou $\delta = 0,80$, identificando 82.531 duplicatas e 7.524 versões *cover* em um corpus de 460.339 letras. A letra com data de lançamento mais antiga é considerada a versão original; versões de artistas distintos são classificadas como *covers* e mantidas no corpus.

3 Pré-processamento textual

3.1 Normalização

As letras são normalizadas por meio das seguintes operações sequenciais: (i) conversão para letras minúsculas; (ii) remoção de pontuação e caracteres especiais; (iii) remoção de marcações estruturais de letras (e.g., “[Refrão]”, “[Verso 1]”, “[Pré-Refrão]”). A estrutura de linhas é preservada ao longo de todo o pré-processamento, pois é necessária para a segmentação em janelas deslizantes utilizada no classificador. A *baseline* não documenta uma etapa de normalização textual explícita, pois o tokenizador interno do BERT representa o único pré-processamento realizado sobre o texto bruto naquele trabalho.

3.2 Tokenização e lematização

A tokenização e a lematização são realizadas com o modelo `pt_core_news_sm` da biblioteca spaCy (versão ≥ 3.0), que provê processamento morfofossintático específico para o português do Brasil. A lematização reduz cada *token* à sua forma canônica (lema), eliminando variações de conjugação verbal,

plural e flexão de gênero. São removidas as *stopwords* da lista padrão do NLTK para o português, complementada por *stopwords* específicas do domínio musical — interjeições de refrão, marcações de repetição e sílabas típicas (e.g., “uh”, “oh”).

O corpus lematizado é armazenado separadamente do corpus normalizado, pois é utilizado simultaneamente para o treinamento do modelo Word2Vec e para a construção dos conjuntos de palavras dos testes WEAT. A *baseline* utiliza o modelo `en_core_web_sm` do spaCy para a lematização do corpus em inglês.

3.3 Léxico de gírias pernambucanas

[Esta seção foi adicionada mais como uma possibilidade, a depender de múltiplos fatores: tangibilidade e tempo]

Uma das principais lacunas da *baseline* é o tratamento exclusivo de textos em inglês, sem capacidade de lidar com variações dialetais ou regionais. Para contornar essa limitação no contexto da RMR, é construído um léxico de gírias e expressões idiomáticas pernambucanas. O léxico é compilado a partir de duas fontes: (i) levantamento bibliográfico em estudos linguísticos sobre o português pernambucano e o léxico do gêneros trabalhados e (ii) análise exploratória do corpus, identificando *tokens* frequentes não cobertos pelo vocabulário padrão do português.

O léxico é estruturado como um dicionário de mapeamento *slang* $\rightarrow$ forma normalizada, mapeando variantes ortográficas, eufemismos e termos de origem regional para seus equivalentes canônicos. O léxico é aplicado ao corpus imediatamente antes da lematização. A construção e validação do léxico constituem uma contribuição metodológica deste trabalho, disponibilizada publicamente para uso em pesquisas futuras no domínio do PLN em português regional.

3.4 Segmentação em lotes para o classificador

O classificador de misoginia foi originalmente projetado para textos curtos (Samory et al., 2021). Para adaptar sua aplicação a letras musicais, cada letra é segmentada em lotes de quatro linhas consecutivas com sobreposição de duas linhas entre lotes adjacentes (janela deslizante). Formalmente, dada uma letra com n linhas $l_1, l_2, \dots, l_n$, o k -ésimo lote B_k é definido como:

$$B_k = \{l_{2k-1}, l_{2k}, l_{2k+1}, l_{2k+2}\} \quad \text{para } k = 1, 2, \dots, \lceil (n-2)/2 \rceil$$

A sobreposição de duas linhas entre lotes adjacentes garante que cada linha seja considerada no contexto das linhas imediatamente anteriores e posteriores, capturando dependências semânticas locais relevantes. Esta estratégia foi introduzida pela *baseline* e é mantida integralmente na presente adaptação.

4 Detecção de misoginia

4.1 Dataset de treinamento e protocolo de anotação

Para o treinamento do classificador em português, são consideradas três alternativas em ordem de preferência: (i) utilização de datasets existentes em português anotados para detecção de misoginia ou discurso de ódio de gênero, incluindo os produzidos nas competições AMI@IberEval, HatEval e OffComBR; (ii) tradução automática seguida de re-anotação do dataset de Samory et al. (2021), que contém textos curtos em inglês anotados com um *codebook* de sexismo baseado em escalas psicológicas validadas; (iii) anotação manual de uma amostra estratificada do corpus de letras dos gêneros analisados.

Caso seja necessário proceder com a anotação manual (opção iii), o *codebook* é adaptado ao contexto cultural, contemplando as seguintes categorias não sobrepostas: (a) objetificação sexual; (b) violência e agressão; (c) controle e posse; (d) degradação; (e) estereótipos de gênero; (f) ausência de conteúdo misógino.

A anotação é realizada por no mínimo três anotadores independentes, e o acordo inter-anotadores é mensurado pelo coeficiente Kappa de Fleiss (κ), com limiar mínimo de $\kappa \geq 0,70$ para garantir confiabilidade adequada (Landis e Koch, 1977). Casos de discordância são resolvidos por adjudicação em sessão conjunta.

4.2 Arquitetura do classificador

O classificador é baseado na arquitetura BERT (*Bidirectional Encoder Representations from Transformers*) (Devlin et al., 2019), na variante BERTimbau (Souza, Nogueira e Lotufo, 2020), especificamente o

modelo *bert-base-portuguese-cased* disponível no repositório *neuralmind* no Hugging Face Model Hub. O BERTimbau foi pré-treinado em um corpus de textos em português brasileiro composto pela Wikipedia PT-BR e o BrWaC (*Brazilian Web as Corpus*), totalizando aproximadamente 2,7 bilhões de *tokens*. Esta escolha representa uma melhoria direta em relação à *baseline*, que utiliza o BERT *base uncased* em inglês.

A camada de classificação consiste em uma camada densa de saída binária (misógino / não misógino) aplicada sobre o vetor do *token* [CLS] da última camada do modelo. O modelo completo é submetido a *fine-tuning end-to-end*, atualizando todos os parâmetros do BERTimbau em conjunto com os da camada de classificação.

4.3 Treinamento e seleção do limiar de classificação

Os hiperparâmetros de treinamento seguem os valores reportados por Betti et al. (2023) como ponto de partida. A Tabela 3 resume a configuração adotada.

Tabela 3: Hiperparâmetros do classificador BERTimbau.

Hiperparâmetro	Valor	Referência
Modelo base	BERTimbau (<i>bert-base-portuguese-cased</i>)	Souza et al. (2020)
Número de épocas	3	Betti et al. (2023)
Batch size	32	Betti et al. (2023)
Taxa de aprendizado	2×10^{-5}	Betti et al. (2023)
Warmup steps	10% do total	Betti et al. (2023)
Otimizador	AdamW	Devlin et al. (2019)
Comprimento máximo	512 <i>tokens</i>	Limite arquitetural do BERT
Limiar θ	Selecionado por max F1-macro em validação	Adaptado de Betti et al. (2023)

O limiar de classificação θ é determinado como o valor que maximiza o F1-*score* macro em um conjunto de validação composto por letras dos gêneros estudados, anotadas manualmente. A *baseline* adotou $\theta = 0,725$, obtendo Precisão = 0,73 e F1-macro = 0,73 em um dataset de 190 letras em inglês. Para o presente trabalho, o limiar é buscado empiricamente no intervalo [0,50; 0,95] com passo de 0,025.

4.4 Avaliação do classificador

A avaliação é conduzida em dois cenários complementares: (i) validação cruzada *k-fold* ($k = 5$) estratificada no dataset de treinamento, reportando Precisão, Revocação, F1-*score* para a classe misógina e F1-*score* macro; (ii) avaliação em um conjunto de letras externas anotadas manualmente (*gold standard*), específico para os gêneros estudados, que verifica a capacidade de generalização do modelo para o domínio das letras musicais em português com vocabulário regional.

4.5 Aplicação ao corpus completo e score por música

O classificador treinado é aplicado a todos os lotes de todas as letras do corpus. Para cada música i , são registrados: (i) a probabilidade de misoginia $p_{i,k}$ de cada lote k ; (ii) o número de lotes classificados como misóginos N_i ; (iii) o score contínuo de misoginia s_i , definido como a média aritmética das probabilidades de misoginia sobre todos os L_i lotes da letra:

$$s_i = \frac{1}{L_i} \sum_{k=1}^{L_i} p_{i,k} \quad s_i \in [0, 1]$$

O score contínuo s_i representa uma extensão relevante em relação à abordagem binária da *baseline*, pois captura a intensidade do conteúdo misógino e é utilizado diretamente no cálculo do Índice de Misoginia.

5 Análise de viés de linguagem

A análise de viés de linguagem mensura as associações semânticas implícitas presentes no corpus de letras, revelando estereótipos de gênero codificados na linguagem dos gêneros musicais estudados. A metodologia segue a abordagem de Betti et al. (2023), baseada nos testes WEAT, SC-WEAT e SWEAT (Caliskan et al., 2017; Charlesworth et al., 2021; Bianchi et al., 2021), com adaptações para o português e para a estratificação adicional por gênero musical.

5.1 Nomes próprios extraídos do corpus

Os nomes próprios constituem um conjunto de palavras-alvo central nos testes de associação carreira-família e inteligência-aparência. A *baseline* extrai nomes a partir do banco de nascimentos do SSA (*Social Security Administration*) dos Estados Unidos (1879–2020) e verifica suas frequências no corpus em inglês. O presente trabalho adota procedimento análogo, substituindo a fonte pelo banco de dados do IBGE (Instituto Brasileiro de Geografia e Estatística), que disponibiliza os nomes próprios mais registrados no Brasil por região e período histórico, acessível via API REST pública.

Os N nomes masculinos e femininos com maior frequência de ocorrência no corpus de letras são selecionados para compor os conjuntos de palavras-alvo, com N determinado para equalizar o tamanho dos conjuntos masculino e feminino ($|\text{nomes_M}| = |\text{nomes_F}|$).

5.2 Construção dos conjuntos de palavras para os testes WEAT

Os conjuntos de palavras para os testes de associação são construídos em três etapas. Na primeira, os conjuntos de atributos e alvos utilizados pela *baseline* são traduzidos para o português e validados por dois pesquisadores bilíngues. Os conjuntos originais são extraídos de Caliskan et al. (2017) e Chaloner e Maldonado (2019), cobrindo as dimensões semânticas listadas na Tabela 4.

Tabela 4: Dimensões semânticas e conjuntos de palavras para os testes WEAT.

Dimensão	Alvo X	Alvo Y	Atributo A	Atributo B
Carreira–Família	Nomes M	Nomes F	Palavras de Carreira	Palavras de Família
Nomes novos (BR)	Nomes BR M	Nomes BR F	Palavras de Carreira	Palavras de Família
Força–Fraqueza	Força	Fraqueza	Nomes M	Nomes F
Inteligência–Aparência	Inteligência	Aparência	Nomes M	Nomes F
Ciência–Arte	Ciência/Mat.	Arte	Nomes M	Nomes F
Ciência–Arte (novo)	Ciência/Mat.	Arte	Atrib. M	Atrib. F

Na segunda etapa, os conjuntos WEAT1 (Caliskan et al., 2017) e WEAT2 (Chaloner e Maldonado, 2019) são combinados por união, formando o conjunto WEAT3, utilizado como referência principal nas análises reportadas.

Na terceira etapa, garante-se a igualdade de cardinalidade $|X| = |Y|$ e $|A| = |B|$, necessária para a correta aplicação dos testes. Palavras que ocorrem menos de 5 vezes em qualquer um dos sub-corpora analisados são descartadas. Quando a remoção de palavras raras cria desigualdade de tamanho, as palavras menos frequentes do conjunto maior são removidas iterativamente.

5.3 Treinamento dos word embeddings

Os *embeddings* de palavras são treinados sobre o corpus lematizado utilizando o algoritmo Word2Vec com arquitetura *skip-gram* (Mikolov et al., 2013), implementado na biblioteca Gensim (Řehůřek e Sojka, 2011). O treinamento é conduzido em duas fases.

Na **primeira fase**, uma busca em grade determina os hiperparâmetros ótimos: dimensão fixada em $d = 300$ e variação de janela $w \in \{3, 5, 7\}$ e épocas $n \in \{20, 40\}$. A qualidade dos *embeddings* é avaliada

com *benchmarks* externos em português (WS353-PT ou LX-Similarity), com avaliação realizada a cada 2 épocas. O parâmetro `min_count = 5` é mantido em todas as configurações.

Na **segunda fase**, o modelo com os hiperparâmetros ótimos — identificados pela *baseline* como $w = 5$ e $n = 40$ — é treinado cinco vezes de forma independente com *seeds* aleatórias distintas (*seeds* 0 a 4), para controle da variabilidade estocástica. Um resultado dos testes de associação é considerado estatisticamente significativo somente quando todos os cinco modelos concordam no nível de significância estabelecido. O treinamento é conduzido separadamente sobre seis sub-corpora: (i) corpus geral; (ii) letras de artistas masculinos; (iii) letras de artistas femininos; (iv) letras de gênero musical x; (v) letras de gênero musical y; (vi) letras de gênero musical z. Os sub-corpora (iv)–(vi) representam uma extensão em relação à *baseline*, que estratifica apenas por gênero do artista.

5.4 Testes de associação: WEAT, SC-WEAT e SWEAT

Os vieses de linguagem são mensurados por três testes complementares.

Word Embedding Association Test (WEAT). O WEAT (Caliskan et al., 2017) mede a associação relativa entre dois conjuntos de palavras-alvo X e Y e dois conjuntos de atributos A e B . A função de associação individual $s(w, A, B)$ de uma palavra w com os conjuntos de atributos é:

$$s(w, A, B) = \text{mean}_{a \in A} \cos(w, a) - \text{mean}_{b \in B} \cos(w, b)$$

A significância estatística é calculada por teste de permutação com 1.000 partições aleatórias. Valores positivos do tamanho do efeito indicam que X está mais associado a A e Y a B .

Single-Category WEAT (SC-WEAT). O SC-WEAT (Charlesworth et al., 2021) desacopla a análise relativa do WEAT, medindo separadamente a associação de cada conjunto-alvo (X ou Y individualmente) com os atributos A e B . Esta capacidade é especialmente relevante quando X e Y têm comportamentos assimétricos em relação aos atributos.

Sliced Word Embedding Association Test (SWEAT). O SWEAT (Bianchi et al., 2021) estende o WEAT para comparar as associações entre dois corpora distintos D_1 e D_2 :

$$S(W, A, B, D_1, D_2) = \sum_{w \in W} s(w, A, B, D_1) - \sum_{w \in W} s(w, A, B, D_2)$$

Um score SWEAT positivo indica que as palavras-alvo em D_1 estão mais associadas ao atributo A do que em D_2 . A agregação dos resultados dos cinco modelos treinados com *seeds* distintas segue o critério da *baseline*: um resultado é considerado significativo no nível ** ($p \leq 0,05$) ou * ($p \leq 0,10$) somente se todos os cinco modelos concordam.

6 Cronograma

Tabela 5: Cronograma de atividades.

	Months											
	J	F	M	A	M	J	J	A	S	O	N	D
Literature review	X	X	X	X	X							
Methodology definition					X							
Data collection						X	X	X				
Implementation and analysis								X	X			
Paper writing									X	X		
Dissertation writing										X	X	X
Defense												X

Referências